Lab3-shortest_path

（一）最小时延路径

（1）链路时延测定原理：

控制器将带有时间戳的 LLDP 报文下发给 s1，s1 转发给 s2，s2 再上传回控制器，控制器根据收到的时间和发送时间即可计算出控制器经 s1 到 s2 再返回控制器的时延，记为 lldp_delay_s12；反之，控制器经 s2 到 s1 再返回控制器的时延，记为 lldp_delay_s21。

交换机收到控制器发来的 Echo 报文后会立即回复控制器，可以利用 Echo Request/Reply 报文分别求出控制器到 s1、s2 的往返时延，记为 echo_delay_s1 和 echo_delay_s2。

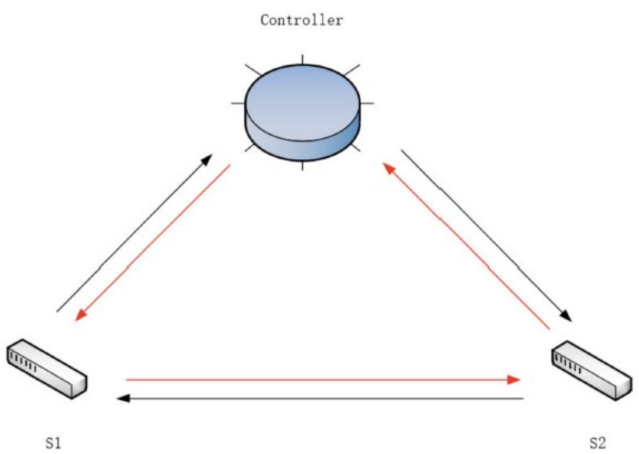

从而可以计算交换机 s1 到交换机 s2 的时延：delay = (lldp_delay_s12 + lldp_delay_s21 - echo_delay_s1 - echo_delay_s2) / 2

（2）对 Ryu 做如下修改：

```python
# in ryu/topology/switches.py class PortData
def __init__(self, is_down, lldp_data):
    super(PortData, self).__init__()
    self.is_down = is_down
    self.lldp_data = lldp_data
    self.timestamp = None
    self.sent = 0
    self.delay = 0  # add
```

PortData 类记录交换机的端口信息，self.timestamp 为 LLDP 包在发送时被打上的时间戳，增加 self.delay 属性用于记录 lldp_delay。

```python
# in ryu/topology/switches.py class Switches
@set_ev_cls(ofp_event.EventOFPPacketIn, MAIN_DISPATCHER)
def lldp_packet_in_handler(self, ev):
    # add receive timestamp
    recv_timestamp = time.time()

    if not self.link_discovery:
        return

    msg = ev.msg
    try:
        src_dpid, src_port_no = LLDPPacket.lldp_parse(msg.data)
    except LLDPPacket.LLDPUnknownFormat:
        # This handler can receive all the packets which can be
        # not-LLDP packet. Ignore it silently
        return

    # calc the delay of lldp packet
    for port, port_data in self.ports.items():
        if src_dpid == port.dpid and src_port_no == port.port_no:
            send_timestamp = port_data.timestamp
            if send_timestamp:
                port_data.delay = recv_timestamp - send_timestamp

    # ...
```

lldp_packet_in_handler()函数负责处理收到的 LLDP 包，这里用收到 LLDP 报文的时间戳减去发送时的时间戳即为 lldp_delay，由于 LLDP 报文经过一跳后转给控制器，因此可将 lldp_delay 存入发送 LLDP 包对应的交换机端口。

完成上述修改后需重新编译安装 Ryu，在安装目录下运行命令 sudo python setup.py install。

（3）获取 lldp_delay：

```python
# in network_awareness.py
def __init__(self, *args, **kwargs):
    super(NetworkAwareness, self).__init__(*args, **kwargs)
    self.switch_info = {}   # dpid: datapath
    self.link_info = {}     # (s1, s2): s1.port
    self.port_link={}       # s1,port:s1,s2
    self.port_info = {}    # dpid: (ports linked hosts)
    self.topo_map = nx.Graph()
    self.topo_thread = hub.spawn(self._get_topology)
    # add
```

```
    self.delay_thread = hub.spawn(self._get_delay)
    self.echo_delay = {}
    self.lldp_delay = {}
    self.switches = None
    self.weight = 'delay'


@set_ev_cls(ofp_event.EventOFPPacketIn, MAIN_DISPATCHER)
def packet_in_handle(self, ev):
    msg = ev.msg
    dpid = msg.datapath.id
    try:
        src_dpid, src_port_no = LLDPPacket.lldp_parse(msg.data)
        if self.switches is None:
            self.switches = lookup_service_brick('switches')
        for port in self.switches.ports.keys():
            if src_dpid == port.dpid and src_port_no == port.port_no:
                self.lldp_delay[(src_dpid, dpid)] =
self.switches.ports[port].delay
    except:
        return
```

上面的代码尝试解析 LLDP 包以获取源交换机 ID 及端口号，然后利用 lookup_service_brick()函数获取正在运行的 switches 的实例，查找其中是否存在源交换机，若有则以(src_dpid, dst_dpid)作为 key，在 self.lldp_delay 中存入时延。

（4）获取 echo_delay：

```
# in network_awareness.py
@set_ev_cls(ofp_event.EventOFPEchoReply, MAIN_DISPATCHER)
def echo_reply_handler(self, ev):
    try:
        echo_delay = time.time() - eval(ev.msg.data)
        self.echo_delay[ev.msg.datapath.id] = echo_delay
    except:
        return
```

控制器在收到 Echo Reply 后，用接收时间戳减去发送时间戳（存储在 echo 包中）获取控制器到交换机的往返时延，并以交换机 ID 作为 key，在 self.echo_delay 中存入时延。

（5）发送 Echo Request 及链路时延的计算：

```
# in network_awareness.py
def _get_delay(self):
```

```python
    while True:
        for dp in self.switch_info.values():
            parser = dp.ofproto_parser
            echo_request = parser.OFPEchoRequest(dp,
data='{:.10f}'.format(time.time()).encode('utf-8'))
            dp.send_msg(echo_request)
            hub.sleep(SEND_ECHO_REQUEST_INTERVAL)

        for edge in self.topo_map.edges:
            src, dst = edge
            if not self.topo_map[src][dst]['is_host']:
                try:
                    lldp_delay_s12 = self.lldp_delay[(src, dst)]
                    lldp_delay_s21 = self.lldp_delay[(dst, src)]
                    echo_delay_s1 = self.echo_delay[src]
                    echo_delay_s2 = self.echo_delay[dst]
                    delay = (lldp_delay_s12 + lldp_delay_s21 -
echo_delay_s1 - echo_delay_s2) / 2.0
                    self.topo_map[src][dst]['delay'] = delay if
delay > 0 else 0
                except:
                    continue
        # if self.weight == 'delay':
        #     self.show_topo_map2()
        hub.sleep(GET_DELAY_INTERVAL)
```

在 NetworkAwareness 类初始化时，使用 hub.spawn()函数在控制器上创建新的协程（coroutine）并周期性发送 Echo Request 与计算链路时延。

在发送 Echo Request 时，每发送一个包就需要休眠一段时间。这是因为控制器调用 dp.send_msg()函数时，会将相应数据包送入消息队列。如果一次性发送大量数据包，则有些数据包可能需要在队列中等待一段时间，而 Echo Request 包中的时间戳是送入队列的时间，而非实际发送的时间。此外，一次性发送数据包时，控制器也几乎同时收到数据包，因此，某些数据包的接收时间戳可能大于实际的接收时间。在计算控制器与交换机之间的往返时延时，是用接收时间戳减去发送时间戳，一次性发送 Echo Reques 包将会导致计算出的 echo_delay 偏大，甚至大于 lldp_delay，这将导致拓扑图中负权边的出现。

因此，在发送 Echo Request 时，每发送一个包就需要休眠一段时间，且计算出的链路时延为负数时应将其记为零，以免计算最小时延路径时出错。

_get_delay()函数在发送完 Echo Request 后，便开始计算链路时延。由于

网络延迟与同步等问题，计算某一条链路的时延时，lldp_delay 与 echo_delay 可能尚未获取，因此将时延计算放在 try 语句块中执行以处理异常。

最后，_get_delay()函数也要休眠一段时间，以让出 CPU 执行其它协程。

（6）获取拓扑（修改）：

```
# in network_awareness.py _get_topology
# update topo_map when topology change
if [str(x) for x in hosts] == _hosts and [str(x) for x in switches]
== _switches and [str(x) for x in links] == _links:
    hub.sleep(GET_TOPOLOGY_INTERVAL)
    continue
_hosts, _switches, _links = [str(x) for x in hosts], [str(x) for x
in switches], [str(x) for x in links]
```

我在_get_topology()函数中做了部分修改，当拓扑保持不变时，函数应休眠一段时间，否则直接使用 continue 进入下一轮循环时，又将发出大量的 LLDP 包，这可能导致网络拥塞而造成交换机转发时延变长。

（7）处理 ARP 环路广播：

```
# in shortest_forward.py
def handle_arp(self, msg, in_port, dst,src, pkt,pkt_type):
    #just handle loop here
    #just like your code in exp1 mission2
    dp = msg.datapath
    ofp = dp.ofproto
    parser = dp.ofproto_parser
    dpid = dp.id
    self.mac_to_port.setdefault(dpid, {})
    header_list = dict((p.protocol_name, p) for p in pkt.protocols
if type(p) != str)

    if dst == ETHERNET_MULTICAST and ARP in header_list:
        arp_dst_ip = header_list[ARP].dst_ip
        if (dpid, src, arp_dst_ip) in self.sw:
            if self.sw[(dpid, src, arp_dst_ip)] != in_port:
                out = parser.OFPPacketOut(datapath=dp,
buffer_id=msg.buffer_id,
                                    in_port=in_port, actions=[], data=None)
                dp.send_msg(out)
                return
        else:
            self.sw[(dpid, src, arp_dst_ip)] = in_port
```

```python
    # self-learning
    self.mac_to_port[dpid][src] = in_port

    if dst in self.mac_to_port[dpid]:
        out_port = self.mac_to_port[dpid][dst]
    else:
        out_port = ofp.OFPP_FLOOD

    actions = [parser.OFPActionOutput(out_port)]

    if out_port != ofp.OFPP_FLOOD:
        match = parser.OFPMatch(in_port=in_port, eth_dst=dst,
eth_type=pkt_type)
        self.add_flow(dp, 1, match, actions, hard_timeout=5)

    data = None
    if msg.buffer_id == ofp.OFP_NO_BUFFER:
        data = msg.data

    out = parser.OFPPacketOut(datapath=dp, buffer_id=msg.buffer_id,
                         in_port=in_port, actions=actions, data=data)
    dp.send_msg(out)
```

这部分代码与之前实验二类似，这里不再赘述。

（8）测试两个交换机之间的时延：

```python
# in network_awareness.py
def show_topo_map2(self):
    self.logger.info('topo map:')
    self.logger.info('{:^10s}  ->  {:^10s}    {:^10s}'.format('node',
'node', 'delay'))
    for src, dst in self.topo_map.edges:
        delay = int(self.topo_map[src][dst]['delay']*1000)
        self.logger.info('{:^10s}      {:^10s}
{:^10s}'.format(str(src), str(dst), str(delay)+'ms'))
    self.logger.info('\n')
```

```
topo map:
 node      ->      node          delay
  1                 9             10ms
  2                 3             10ms
  2                 4             14ms
  3                 4             14ms
  4                 5             15ms
  5                 9             31ms
  5                 6             18ms
  6                 7             10ms
  7                 8             64ms
  8                 9             18ms
```

测量出的链路时延与理论值的误差在 1-2ms 内。

（8）运行结果：

```
PING 10.0.0.3 (10.0.0.3) 56(84) bytes of data.
64 bytes from 10.0.0.3: icmp_seq=2 ttl=64 time=78.6 ms
64 bytes from 10.0.0.3: icmp_seq=3 ttl=64 time=131 ms
64 bytes from 10.0.0.3: icmp_seq=4 ttl=64 time=135 ms
64 bytes from 10.0.0.3: icmp_seq=5 ttl=64 time=132 ms
^C
--- 10.0.0.3 ping statistics ---
6 packets transmitted, 4 received, 33% packet loss, time 5039ms
rtt min/avg/max/mdev = 78.652/119.424/135.035/23.572 ms
```

```
test@sdnexp:~/Desktop/sdn_exp/sdn_exp-3$ ryu-manager shortest_forward.py --obser
ve-links
loading app shortest_forward.py
loading app ryu.topology.switches
loading app ryu.controller.ofp_handler
instantiating app None of NetworkAwareness
creating context network_awareness
instantiating app shortest_forward.py of ShortestForward
instantiating app ryu.topology.switches of Switches
instantiating app ryu.controller.ofp_handler of OFPHandler
host not find/no path
path: 10.0.0.5 -> 10.0.0.3
10.0.0.5 -> 1:s6:2 -> 4:s5:3 -> 3:s9:4 -> 3:s8:1 -> 10.0.0.3
```

从上图中可以发现，SDC ping MIT 时，选择了最小时延路径进行转发，往返时延与最小时延理论值（126ms）的差异在 5-10ms 间，而另一条最小跳数路径的理论时延为 144ms。

此外，第一次 ping 的时延明显小于后面，这是因为 SDC 将 ICMP 包发给连接的交换机时，匹配默认流表后转发给控制器，控制器根据 ICMP 包的源 IP 地址与目的 IP 地址，计算出最小时延路径，并将流表项下发给路径上的各个交换机。之后，控制器直接将 ICMP 包发送给连接 MIT 的交换机。MIT 在发送 ICMP 响应包时则通过匹配刚才下发的流表项，通过最小时延路径上转发给 SDC。因此，第一次 ping 的时延略大于往返时延的一半。

（二）容忍链路故障

（1）处理链路故障原理：

当链路状态改变时，链路关联的端口状态也会改变，从而产生端口状态改变的事件，即 EventOFPPortStatus，将该事件与处理函数绑定在一起，就可以获取状态改变的信息，并执行相应的处理。

当链路状态改变时，控制器删除网络拓扑中所有交换机上除默认流表以外的流表项，下一次交换机收到数据包后将会匹配默认流表项，向控制器发送packet_in 消息，控制器重新计算最小时延路径并下发流表。

（2）删除流表：

```
# in shortest_forward.py
def del_flow(self, datapath, match):
    ofp = datapath.ofproto
    parser = datapath.ofproto_parser
    mod = parser.OFPFlowMod(
            datapath, command=ofp.OFPFC_DELETE,
            out_port=ofp.OFPP_ANY, out_group=ofp.OFPG_ANY,
            priority=1, match=match)
    datapath.send_msg(mod)
```

OFPFC_DELETE 用于删除指定流表中符合匹配规则（部分匹配即可）的流表项，del_flow()函数将指定交换机中满足匹配域的流表项删除。

（3）链路状态改变处理函数：

```
# in shortest_forward.py
@set_ev_cls(ofp_event.EventOFPPortStatus, MAIN_DISPATCHER)
def port_status_handler(self, ev):
    msg = ev.msg
    dp = msg.datapath
    ofp = dp.ofproto
    parser = dp.ofproto_parser

    if msg.reason in [ofp.OFPPR_ADD, ofp.OFPPR_MODIFY]:
        dp.ports[msg.desc.port_no] = msg.desc
    elif msg.reason == ofp.OFPPR_DELETE:
        dp.ports.pop(msg.desc.port_no, None)
    else:
        return

    switches = get_switch(self)
    for switch in switches:
        datapath = switch.dp
        match = parser.OFPMatch(eth_type=0x0800)
        self.del_flow(datapath, match)
        match = parser.OFPMatch(eth_type=0x0806)
        self.del_flow(datapath, match)

    self.mac_to_port = {}
    self.sw = {}
```

```
    self.network_awareness.topo_map.clear()

    self.send_event_to_observers(
        ofp_event.EventOFPPortStateChange(dp, msg.reason,
msg.desc.port_no),
        dp.state
    )
```

当链路状态改变时，将执行 port_status_handler()处理函数，该函数遍历网络拓扑中的每个交换机，删除控制器先前下发的协议类型为 ARP 与 IPV4 的流表项，并清除拓扑图。

（4）运行结果：

在 mininet 中使用 link down 与 link up 来模拟链路故障与故障恢复。刚开始，SDC 与 MIT 间的最小时延链路为 s6-s5-s9-s8，理论时延为 126ms。当 s9 与 s8 之间链路故障时，最小时延链路为 s6-s7-s8，理论时延为 144ms。

```
mininet> link s9 s8 down
mininet> SDC ping MIT
PING 10.0.0.3 (10.0.0.3) 56(84) bytes of data.
64 bytes from 10.0.0.3: icmp_seq=1 ttl=64 time=84.4 ms
64 bytes from 10.0.0.3: icmp_seq=2 ttl=64 time=151 ms
64 bytes from 10.0.0.3: icmp_seq=3 ttl=64 time=150 ms
64 bytes from 10.0.0.3: icmp_seq=4 ttl=64 time=158 ms
64 bytes from 10.0.0.3: icmp_seq=5 ttl=64 time=150 ms
64 bytes from 10.0.0.3: icmp_seq=6 ttl=64 time=150 ms
^C
--- 10.0.0.3 ping statistics ---
7 packets transmitted, 6 received, 14% packet loss, time 6012ms
rtt min/avg/max/mdev = 84.484/141.194/158.411/25.508 ms
mininet> link s9 s8 up
mininet> SDC ping MIT
PING 10.0.0.3 (10.0.0.3) 56(84) bytes of data.
64 bytes from 10.0.0.3: icmp_seq=1 ttl=64 time=74.7 ms
64 bytes from 10.0.0.3: icmp_seq=2 ttl=64 time=139 ms
64 bytes from 10.0.0.3: icmp_seq=3 ttl=64 time=134 ms
64 bytes from 10.0.0.3: icmp_seq=4 ttl=64 time=134 ms
64 bytes from 10.0.0.3: icmp_seq=5 ttl=64 time=133 ms
^C
--- 10.0.0.3 ping statistics ---
5 packets transmitted, 5 received, 0% packet loss, time 4008ms
rtt min/avg/max/mdev = 74.753/123.253/139.163/24.333 ms
```

```
test@sdnexp:~/Desktop/sdn_exp/sdn_exp-3$ ryu-manager shortest_forward.py --obser
ve-links
loading app shortest_forward.py
loading app ryu.topology.switches
loading app ryu.controller.ofp_handler
instantiating app None of NetworkAwareness
creating context network_awareness
instantiating app shortest_forward.py of ShortestForward
instantiating app ryu.topology.switches of Switches
instantiating app ryu.controller.ofp_handler of OFPHandler
host not find/no path
path: 10.0.0.5 -> 10.0.0.3
10.0.0.5 -> 1:s6:2 -> 4:s5:3 -> 3:s9:4 -> 3:s8:1 -> 10.0.0.3
path: 10.0.0.5 -> 10.0.0.3
10.0.0.5 -> 1:s6:3 -> 2:s7:3 -> 2:s8:1 -> 10.0.0.3
path: 10.0.0.5 -> 10.0.0.3
10.0.0.5 -> 1:s6:2 -> 4:s5:3 -> 3:s9:4 -> 3:s8:1 -> 10.0.0.3
```

从上图中可以发现，当链路故障时，最小时延链路相应发生了改变，而当故障恢复后，最小时延链路也得到了恢复。